Phase 4 Sanity Report — LongMemEval Oracle (30 questions, stratified)

날짜: 2026-04-26 **Scale**: subset 30 questions = 5/qtype × 6 question_type **Data**: `benchmarks/LongMemEval/data/longmemeval_oracle.json` **Model**: `Qwen/Qwen3-8B` (vLLM 로컬, 응답·judge 동일 endpoint, 비용 0) **Hi-EM HP**: persistence (α=1, λ=10, σ²=0.01) — 옵션 5 결정 그대로 **Hi-EM Memory window**: k_topics=3, k_turns_per_topic=5 (= max 15 turns) **RAG K**: 10 **Sliding K**: 20

---

1. 결과 — 4-way Accuracy 비교

Method	Overall	knowledge	multi	ssa	ssp	ssu	temporal
sliding K=20	0.700 (21/30)	0.80 (4/5)	0.20 (1/5)	1.00 (5/5)	0.80 (4/5)	0.80 (4/5)	0.60 (3/5)
full	**0.833 (25/30)**	0.80	0.60	1.00	1.00	0.80	0.80
rag K=10	0.733 (22/30)	0.60	0.20	1.00	0.80	0.80	**1.00**
hi-em	**0.633 (19/30)** ⚠️	**0.20** ⚠️	**0.00** ⚠️	1.00	0.80	**1.00**	0.80

> **Hi-EM이 4 method 중 꼴찌 overall.** multi-session 5/5 fail, knowledge-update 4/5 fail.

2. 진단 — 파이프라인 vs 알고리즘

2.1 파이프라인 정상 (검증됨)

- 단위 테스트 58/58 PASS (preload_history, return_debug, A→B→A 토픽 복귀 포함)
- ssu 5/5, ssa 5/5, temporal 4/5 — **단일 세션 + 연속 정보에선 baseline 수준 동작**
- LTM state.json 직접 검사: history 24~46 turns가 모두 정확히 저장, segmenter가 topic 부여

→ **코드 결함 아님**.

2.2 알고리즘/HP 한계 (multi-session LTM state 분석)

multi-session 5/5 fail의 LTM state:

QID	n_topics	max topic count	history turns	패턴
gpt4_59c863d7	**1**	[24]	46	모든 user turn이 한 cluster — persistence HP 너무 sticky
6d550036	9	[3,3,3,3,3]	44	적당히 분리, but k_topics=3 → 6 topic 누락
b5ef892d	7	[3,3,3,3,3]	36	동일

QID	n_topics	max topic count	history turns	패턴
e831120c	5	[3,3,3,3,1]	24	동일
0a995998	6	[3,3,3,3,3]	34	동일

두 패턴:

- **(case 1)** persistence HP λ=10이 너무 강해 모든 turn이 한 토픽 → topic ID 부여 의미 무효 → 5 turns만 보고 답
- **(case 2~5)** 분리는 됐으나 `k_topics=3 × k_turns_per_topic=5 = 15 turns` budget이 multi-session 정답 분포(history 곳곳)에 부족

knowledge-update 4/5 fail도 비슷한 원인 추정 — 같은 주제 update가 한 topic 안에 stale + new 둘 다, recency tail 5 turn 안에 new 안 들어가면 fail.

2.3 강점

- ssu 1.00 (full=0.80, rag=0.80) — **단일 user 세션에선 Hi-EM이 다른 baseline보다 약간 우위**
- temporal 0.80 — full과 동등 (RAG 1.00은 cosine top-K가 시간 정보 잘 잡는 듯)
- ssa 1.00, ssp 0.80 — baseline과 동등

→ Hi-EM의 토픽 ID·centroid 메커니즘은 **단일 세션 + 분명한 주제 영역**에서 정상 동작.

3. 한계

1. **표본 5/qtype은 noise 큼** (±20% 변동). 전체 oracle 500으로 검증 필요.
2. **prefill_tokens 미기록**: 현재 jsonl은 hypothesis만. token 효율 axis (Hi-EM이 적은 token으로 비슷한 acc?) 비교 불가. wandb엔 있으나 사용자 환경에서 wandb 연결 이슈로 chart 미확인.
3. **HP 단일 측정**: persistence HP만 시도. freq-shift HP (α=10, λ=1, σ^2=0.1)는 보류 — 옵션 5 ARI 기준으론 약했지만 multi-session에선 다를 수도.
4. **k_topics=3, k_turns_per_topic=5 단일 측정**: token budget이 RAG K=10보다 1.5x 크지만 multi-session엔 부족할 수 있음.

4. Phase 1-6 reframing 정합성 재검토

옵션 3 reframing의 핵심 가정:

> "boundary F1·ARI는 Hi-EM 가치 지표 아님. **downstream QA에서 진짜 측정**."

본 sanity 결과:

- **현재 HP·k 조합으로는 Hi-EM이 baseline에 명확히 패배**
- 단 강점 영역(ssu, temporal) + 약점 영역(multi, knowledge-update) 분명
- "Hi-EM은 단일 세션 + 한 주제 깊이 추적엔 강하지만, 분산 정보 + 업데이트엔 RAG/full보다 약하다"는 잠정 결론

Phase 5 (논문) 진입 자격은 **HP sweep 후 best Hi-EM이 한 능력 이상에서 baseline 우위 또는 동등 + token 효율 우위** 충족 시.

5. 다음 단계 후보

옵션	비용	기대
A. HP/k sweep	1~2시간	k_topics=5, k_turns_per_topic=10 + freq-shift HP. multi-session winning region 탐색
B. jsonl에 prefill_tokens 추가 + 재실행	5분 fix + 재실행	token 효율 axis 확보 — Hi-EM이 적은 token으로 비슷한 acc면 의미 있음
C. oracle 전체 500으로 검증	~수 시간	5/qtype noise vs 진짜 차이 분리
D. 결과 인정 + Phase 4 reframing 재서술	즉시	"Hi-EM은 ssu/temporal 강점, multi/knowledge 약점 명확 — 정직 기록 후 Phase 5 plan 재고"

권고 순서: B → A → C → D

1. B: token 효율 axis 없으면 Hi-EM 가치 평가 불가능한 채로 결정 못 내림
2. A: HP sweep으로 winning region 있나 확인 (없으면 D)
3. C: best HP로 큰 sample 검증
4. D: 결과 위에 정직한 결론

6. 검증 미해결

- **prefill_tokens 정량**: 즉시 fix 가능 (B)
- **HP regime 다양성**: persistence vs freq-shift sweep 필요 (A)
- **Sample size**: 5/qtype → 100/qtype 필요 (C)
- **knowledge-update 0.20의 직접 원인**: stale-vs-new 가설 미검증 — case별 LTM 검사 필요

7. 참고 산출물

- 4 hypothesis jsonl: `outputs/phase-4-sanity-{sliding,full,rag,hi-em}.jsonl`
- 4 judge result: `outputs/phase-4-sanity-{sliding,full,rag,hi-em}.jsonl.judged.jsonl`
- LTM state per question: `data/ltm/longmemeval/<conv_id>/{*.jsonl, *.state.json}` (gitignored)
- Codex review 메트릭 결정: `context/06-decision-log.md` 2026-04-26 entry